Agentic AI 场景下 KV 卸载的系统综述

Agentic AI 场景下 KV 卸载的系统综述

> Updated: 2026-04-24
> Scope: 综述 `agentic AI` 工作负载如何改变 `KV cache offloading` 的访问模式、系统瓶颈与分层架构，并讨论这些变化对 CPU 设计的启示。本文重点覆盖 2024-2026 的公开论文与厂商技术资料，尤其关注 `pause-resume`、多 agent 扇出、分层 KV 存储、预取与 CPU 侧内存通路。

摘要

Agentic AI 正在改变大模型推理系统对 KV cache 的处理方式。与传统聊天式推理相比，agentic workload 具有更长的会话生命周期、更频繁的工具调用与中断恢复、更高的前缀共享度，以及更显著的跨请求 KV 复用需求。这些特征使 KV 卸载从“GPU 显存不足时的补救机制”演化为支撑吞吐、时延与成本优化的核心系统能力。本文综述了 2024-2026 年公开研究与工业实践中关于 agentic AI、KV 卸载、共享前缀复用、暂停恢复、分层存储和 CPU-GPU 协同内存的主要进展。综述表明，agentic AI 将 KV 访问模式显著推向 `write-once-read-many`，并强化了 `preserve / swap / prefetch / routing-aware reuse` 等机制的重要性。相应地，CPU 不再只是慢速 spill 目的地，而逐渐成为 GPU 之外的首层可用容量与共享层。本文最后从主机侧带宽、页表与 pinning 成本、分层内存语义、异步预取和轻量数据变换等方面，总结其对 CPU 设计的主要启示。

1. 引言

随着 coding agent、research agent、browser agent 和 tool-using assistant 的快速普及，推理系统正从“单轮生成”转向“长生命周期、多阶段、可中断、可恢复、可共享”的工作模式。在这类场景中，模型已生成上下文所形成的 KV cache 不再只是一次请求的临时状态，而是跨多次调用、跨多个 worker、甚至跨多个 agent 共享的系统资源。

这一变化直接抬高了 KV 卸载的重要性。过去，KV offload 的主要目标是缓解 GPU 显存压力、支持更长上下文；而在 agentic AI 场景下，它还承担了避免重算、降低冷启动成本、支撑多 agent 前缀共享、提升中断恢复效率等额外职责。因此，理解 agentic AI 对 KV 卸载带来的差异化影响，已经成为评估未来 CPU、内存与异构系统设计的重要前提。

2. 概念与问题边界

2.1 KV 卸载的定义

KV 卸载是指把原本常驻 GPU 显存的 key-value cache 迁移到 CPU 内存、本地 SSD 或远端存储，并在后续请求中按需重新加载，以换取更高并发、更长上下文支持或更低重算成本。其本质是把 KV cache 从单层显存对象改造成跨层次、可迁移、可调度的数据结构。

2.2 Agentic AI 与传统聊天式推理的差异

传统聊天式推理通常具有较短生命周期、较低中断频率和较弱前缀共享；而 agentic AI 带来三类显著变化：

- **多轮长会话**：上下文持续累积，KV 生命周期显著延长。
- **工具调用与暂停恢复**：外部工具、环境响应和人类反馈会频繁打断生成。
- **多 agent 扇出与共享前缀**：主 agent 与子 agent 往往共享 system prompt、tool definitions 和会话前缀。

2.3 本文关注的问题

本文聚焦三个问题：

1. agentic AI 如何改变 KV cache 的访问模式与生命周期？
2. 当前公开系统如何处理 pause-resume、共享前缀、KV 分层与预取？
3. 这些变化对 CPU 的内存、互连和系统角色提出了哪些启示？

3. Agentic AI 改变 KV 访问模式

3.1 从短时状态到共享状态

在 agentic 场景中，首轮请求生成的 KV 往往会在后续几十次甚至上百次调用中持续复用。例如，coding agent 会在同一会话中反复携带相同的 system prompt、工具定义、项目上下文和中间结果。这样一来，KV cache 的价值不再由“单次 decode 的命中收益”决定，而更多由其 **跨请求、跨阶段的复用价值** 决定。

3.2 从写后少量读到 write-once-read-many

NVIDIA 在 2026-04-17 发布的 `Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo` 中指出，agentic inference 呈现出明显的 `write-once-read-many (WORM)` 特征。文中给出：

- 同一 worker 上后续调用 **85%-97% cache hit**
- 4 个 agent teammate 聚合后 **97.2% cache hit**
- **11.7x read/write ratio**

这些数据表明，在 agentic AI 中，系统压力正从“频繁写入新 KV”转向“如何保留、共享、路由和预取旧 KV”。

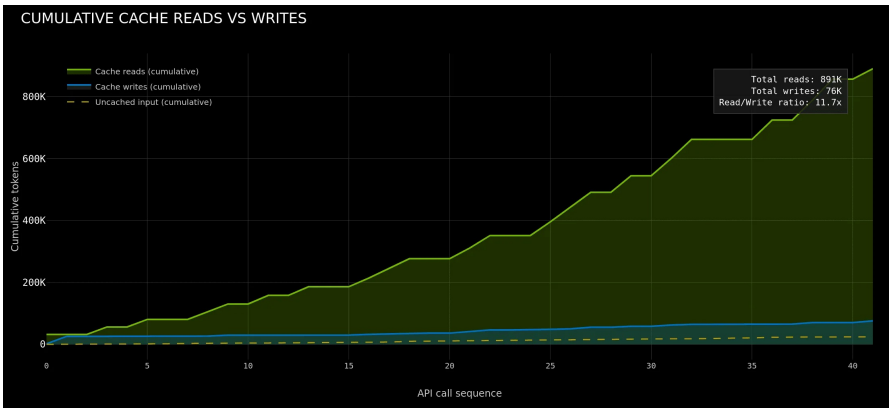

图：在 agentic inference 中，累计 KV 读取明显快于写入，反映出共享前缀和多次复用带来的 WORM 模式。
来源：NVIDIA《Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo》。

3.3 中断恢复成为常态

Agentic AI 并非连续生成到底，而是频繁经历“生成一段 -> 调工具 -> 等返回 -> 继续生成”的模式。这使得 KV 在暂停期间虽然暂时不用，但恢复时又必须快速可用。由此，系统必须决定是：

- 丢弃 KV，恢复时重算
- 保留 KV，等待恢复
- 交换到 CPU/外存，再在恢复时取回

也正是在这一点上，agentic AI 与传统推理系统的差异最为明显。

4. 主要系统路线与研究进展

4.1 丢弃、保留与交换：INFERCEPT 对中断处理的分析

INFERCEPT（2024）直接研究了 augmented / intercepted LLM inference。论文指出，现有系统往往把 interception 当作请求结束，恢复时重新发起请求并重算上下文；这种 `Discard` 策略会带来明显浪费。论文测得：

- **37%-40%** 的总模型 forwarding 时间会浪费在已算过上下文的重算上
- 其改进系统可实现 **1.6x-2x** 的吞吐提升，并完成 **2x 更多请求/秒**

INFERCEPT 的贡献在于把 `Discard`、`Preserve`、`Swap` 与自适应调度放在同一框架中比较，从而说明：在 agentic 场景中，KV 不只是缓存对象，更是中断恢复语义的一部分。

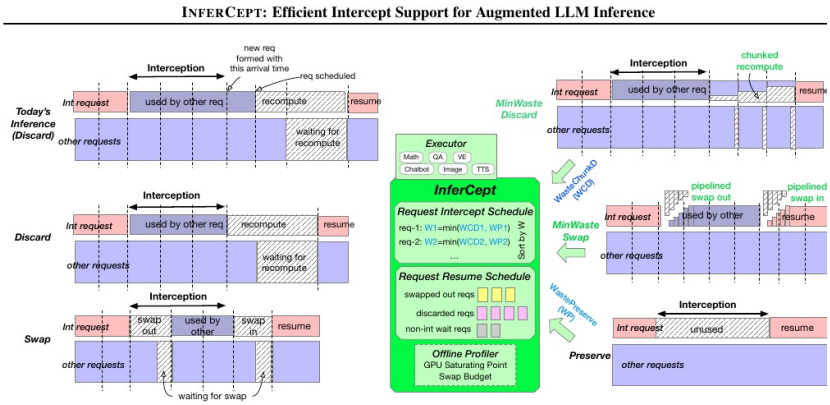

Figure 1: **INFERCEPT and Alternative Approaches.** *Vertical: GPU resources occupied or wasted by intercepted requests and other normal ones. Horizontal: timeline divided by iterations (dotted vertical lines). Hatch parts represent memory waste.* INFERCEPT *adaptively combines preserve, our optimized discard, and our optimized swap. All green parts represent* INFERCEPT*'s techniques.*

图：INFERCEPT 对比了 `Discard`、`Swap`、`Preserve` 与自适应策略。它说明 agentic/augmented LLM 的核心不只是生成，而是如何在中断期间处理已存在的 KV。
来源：INFERCEPT 论文 Figure 1。

4.2 分层 KV 存储：从本地显存管理到跨层次系统

NVIDIA 2025-09-18 的 `How to Reduce KV Cache Bottlenecks with NVIDIA Dynamo` 将 KV offload 明确扩展到：

- CPU RAM
- local SSD
- remote/network storage

这一表述值得注意，因为它意味着工业界已不再把 KV offload 看成“GPU 内存不够时的临时 spill”，而是把它当成 **层次化容量与共享架构**。在长会话、高并发、共享模板或研究型工作流中，offload 的收益不止来自节省显存，还来自减少重算和提升共享命中率。

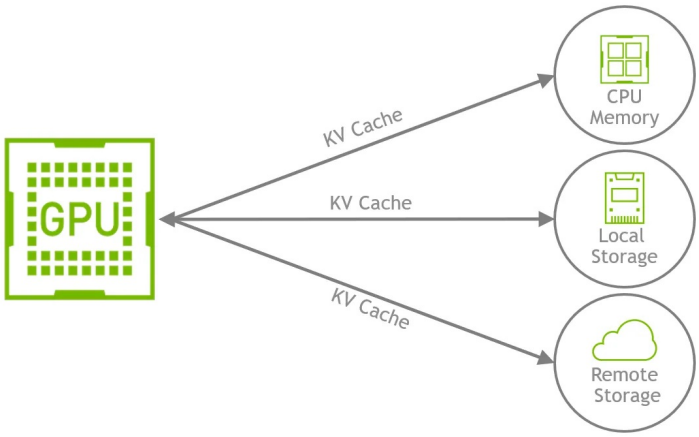

图：NVIDIA 给出的 KV offloading 架构图，强调 GPU 可把 KV 转移到更大、更便宜的存储层。
来源：NVIDIA《How to Reduce KV Cache Bottlenecks with NVIDIA Dynamo》。

4.3 共享前缀与状态感知调度

Preble（2024）研究的是 distributed prompt scheduling，但其发现与 agentic AI 高度相关：随着 prompt 更长、共享前缀更多、请求状态更复杂，调度系统必须考虑状态放置和复用，而不能只按传统负载均衡逻辑分发请求。对于 agentic AI 而言，多 agent 扇出恰恰会放大这一问题，因为多个 subagents 经常共享同一套工具定义和系统上下文。

4.4 预取：agentic AI 的关键补充机制

与传统 offload 不同，agentic AI 的工作流经常具备可预测性。Agent harness 往往知道工具调用何时可能返回，因此可以提前推测“下一次请求将需要哪些 KV 块”。这使得 `prefetch` 从存储系统中的常见优化，上升为推理生命周期管理的核心机制。

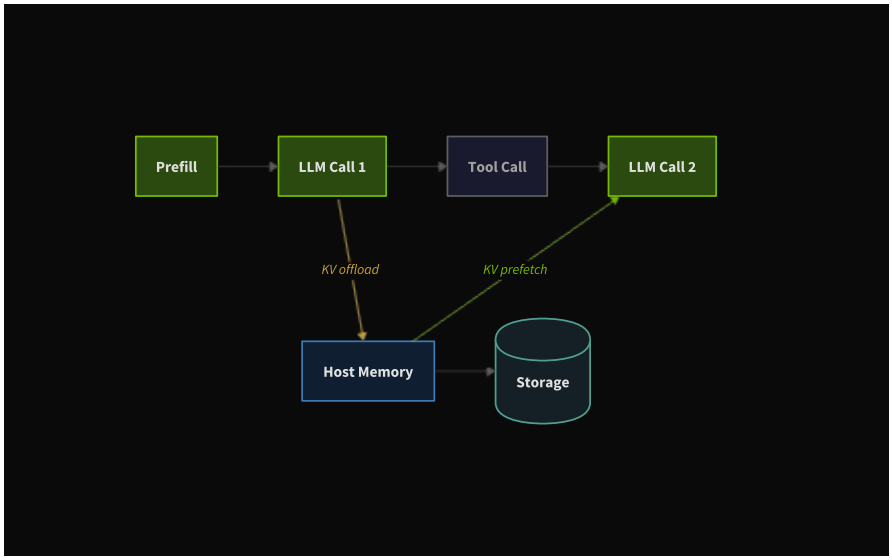

图：工具调用后，KV 先被卸到主机/存储侧，再在第二次 LLM 调用前主动预取回 GPU。对 agentic AI 来说，预取和卸载是成对出现的。
来源：NVIDIA《Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo》。

4.5 统一内存与 CPU-GPU 协同

NVIDIA 在 2025-09-05 的 `Accelerate Large-Scale LLM Inference and KV Cache Offload with CPU-GPU Memory Sharing` 中强调，Grace Hopper / Grace Blackwell 通过 **NVLink-C2C 900 GB/s** 的 coherent interconnect，将 CPU 与 GPU 放入统一内存地址空间。

这类设计的意义不只是“让更大模型装下”，更在于：

- CPU 内存可作为低摩擦的 KV staging / overflow / sharing 层
- GPU 不必每次显式复制与迁移数据
- 长会话、长上下文和 pause-resume 工作流的恢复路径更短

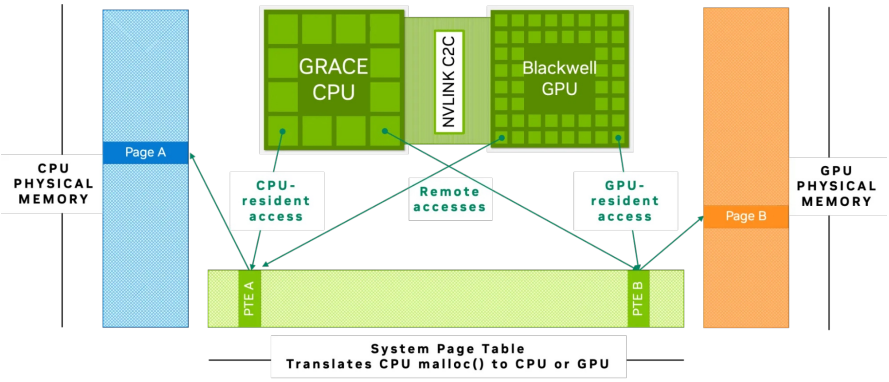

图：CPU 与 GPU 通过统一页表共享内存地址空间，说明 CPU 侧内存可以更自然地成为 KV 的延伸容量层。
来源：NVIDIA《Accelerate Large-Scale LLM Inference and KV Cache Offload with CPU-GPU Memory Sharing》。

5. Agentic AI 对 KV 卸载带来的差异化影响

5.1 KV 生命周期显著延长

在普通聊天式推理中，KV 往往随单轮请求生命周期结束而失去价值；在 agentic AI 中，会话状态、工具定义和中间推理上下文可能在长时间内持续复用。因此，KV 的经济性从“短时命中”转向“长期保留后的多次复用”。

5.2 KV 卸载的收益从节省显存扩展到避免重算

普通聊天中，offload 主要服务于容量扩展；而在 agentic AI 中，它还用于：

- 保住工具调用前已生成的上下文
- 在恢复时避免重新 prefill
- 在多个 subagents 间共享前缀

也就是说，offload 的价值不再只是“让模型放得下”，而是“让系统不必重复做已经做过的计算”。

5.3 路由与保留策略的重要性上升

由于 agentic workload 的前缀共享高、请求中断频繁，系统不仅要知道“KV 在哪里”，还要知道“哪些 KV 更值得保留”和“下一次请求最可能在哪个 worker 上运行”。这使 eviction policy、retention hint、TTL、priority queue 和 worker affinity 都成为关键议题。

5.4 CPU 从慢速兜底层变为温热容量层

当 KV 卸载主要面对长会话、pause-resume 和多 agent 共享前缀时，CPU 内存的角色会从“远端 spill 层”转向“GPU 外的首层温热容量层”。也就是说，CPU 内存不只是比 SSD 快，而是足够快到可以直接参与恢复、复用和预取。

6. 对 CPU 设计的启示

本文并不把这些结论视为“现成设计规范”，但基于公开资料，可以归纳出几项稳定的 CPU 设计启示。

6.1 主机侧带宽需要进入推理关键路径

如果 CPU 内存承担温热 KV 层，其价值就不再只是容量，而是 **能否在恢复路径中足够快地把 KV 送回 GPU**。因此，CPU-GPU 互连的峰值带宽固然重要，但更关键的是 tail latency、coherency 成本和可持续的数据流能力。

6.2 页表、pinning 与 IOMMU 成本会放大

KV block 大、数量多、生命周期长，agentic workload 又会引入频繁的暂停、恢复和复用。这意味着 pinned memory 管理、大页覆盖、TLB 效率、页表遍历和 IOMMU 映射更新，都会对系统表现产生更直接的影响。

6.3 分层内存语义会比单层 DRAM 更重要

对 agentic AI 而言，更合理的结构通常不是单一 DRAM，而是：

- GPU HBM：最热 KV
- CPU DRAM：即将恢复、即将复用的温热 KV
- SSD / remote / pooled memory：冷 KV、共享 KV 和持久 KV

因此，NUMA、QoS、memory pooling 与未来 CXL.mem 的价值，会随着 agentic workload 的普及而提升。

6.4 预取与异步生命周期控制值得硬件友好支持

agentic AI 使“提前知道下一步会用到哪些 KV”成为可能，这使异步 copy、prefetch、DMA pipeline 和与软件协作的 lifecycle hint 更具价值。未来 CPU/SoC 在 supporting engine orchestration 上可能会出现更多面向 KV 语义的优化。

6.5 轻量数据变换路径的重要性提升

若未来 KV block 进一步压缩、量化、去重、哈希寻址，CPU 侧还会承担更多轻量数据变换任务，如 block hashing、checksum、压缩解压和热点前缀复制。这将提升向量化 memcpy、数据校验和小粒度数据变换的架构价值。

7. 文献与证据整理

Year	Title	Type	Topic	Main finding	Releva
	INFERCEPT:				

2024	Efficient Intercept Support for Augmented Large Language Model Inference	论文	pause-resume / interception	丢弃 KV 会导致 37%-40% 的前向时间浪费；INFERCEPT 提升 1.6x-2x 吞吐	直接说明 agentic/aug workload 保留与卸载成为 题
2024	Preble: Efficient Distributed Prompt Scheduling for LLM Serving	论文	共享前缀 / stateful scheduling	长 prompt 与前缀共享让分布式调度必须考虑 state placement	支撑 agentic agent 共享前 KV 系统的要
2025	Introducing New KV Cache Reuse Optimizations in NVIDIA TensorRT-LLM	厂商技术文档	KV eviction / retention	priority-based eviction 和 event API 可提升命中与路由能力	说明 KV 管理 LRU 转向 workload-a 策略
2025	How to Reduce KV Cache Bottlenecks with NVIDIA Dynamo	厂商技术文档	KV offload hierarchy	KV 可卸到 CPU RAM、SSD、network storage；适合长会话、高并发、共享内容	说明工业界已 offload 视为 统
2025	Accelerate Large-Scale LLM Inference and KV Cache Offload with CPU-GPU Memory Sharing	厂商技术文档	CPU-GPU unified memory	NVLink-C2C 900 GB/s coherent interconnect 让 CPU 内存更自然承担 KV overflow/offload	直接关联 CP 与 KV 卸载效
2026	Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo	厂商技术文档	agentic inference / KV lifecycle	85%-97% cache hit、97.2% aggregate hit、11.7x read/write ratio；强调 routing、retention、prefetch	直接回答 ag 如何改变 KV 题性质

8. 图表附录

图 A. Agentic inference 的 KV 访问呈现明显读多写少

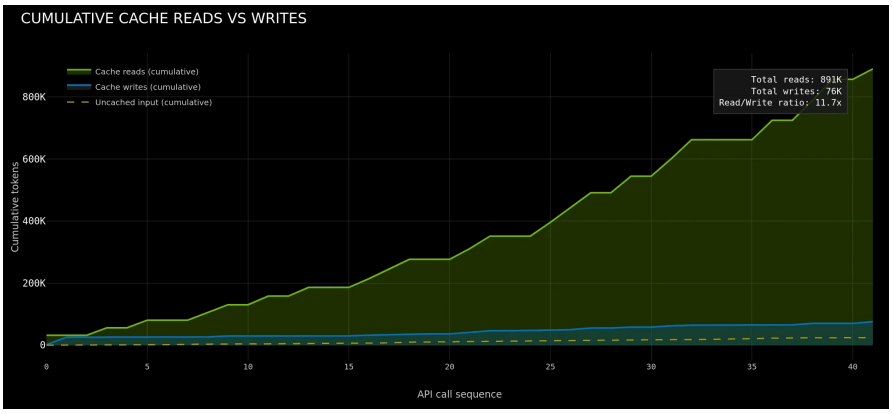

这张图表明，在 agentic workload 中，KV 的主要压力来自“高复用、高保留、高读取”，而不是单次请求里不断写新 KV。
来源：NVIDIA《Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo》。

图 B. pause-resume 让 preserve/offload 比 discard 更重要

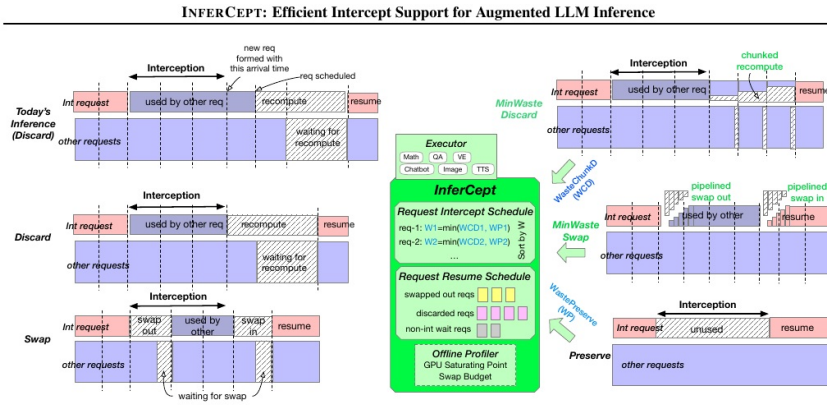

Figure 1: **INFERCEPT and Alternative Approaches.** *Vertical: GPU resources occupied or wasted by intercepted requests an other normal ones. Horizontal: timeline divided by iterations (dotted vertical lines). Hatch parts represent memory waste.* INFERCEP *adaptively combines preserve, our optimized discard, and our optimized swap. All green parts represent* INFERCEPT*'s techniques.*

这张图展示了 agentic/augmented LLM 在工具调用中断后，不同 KV 处理策略的资源浪费差异。
来源：INFERCEPT Figure 1。

图 C. 卸载和预取在 agentic AI 中是成对优化

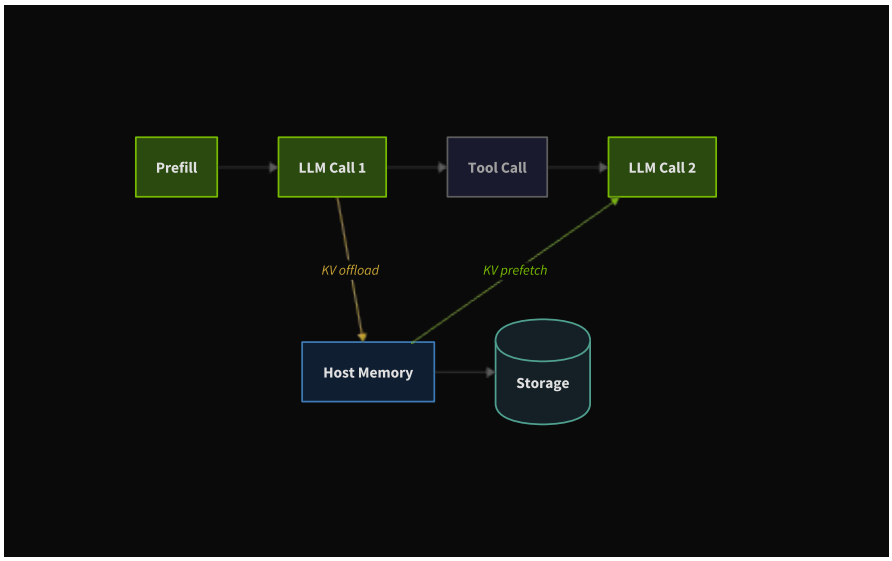

这张图表明：对 agentic AI 来说，CPU/存储层不仅要能接住 offload，还要能在下次调用前把 KV 提前送回 GPU。
来源：NVIDIA《Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo》。

图 D. CPU-GPU 统一地址空间使 CPU 更像首层温热容量层

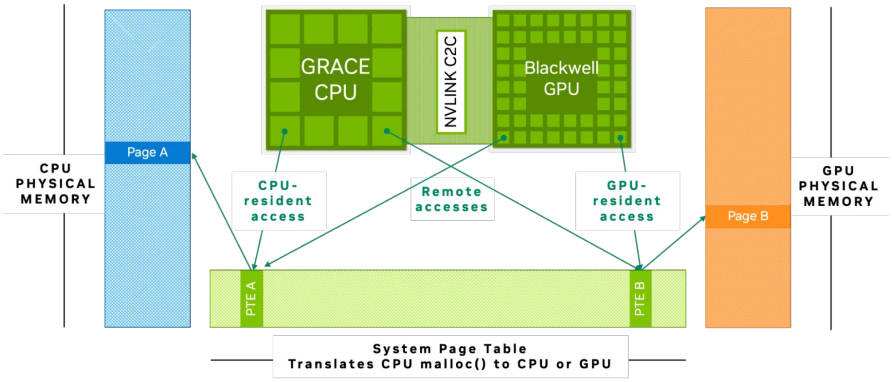

这张图说明：当 CPU 与 GPU 真正共享地址空间和高带宽一致性互连时，CPU 内存就不再只是“远端内存”，而更像 KV 的延伸容量层。
来源：NVIDIA《Accelerate Large-Scale LLM Inference and KV Cache Offload with CPU-GPU Memory Sharing》。

9. 结语

总体来看，agentic AI 并未改变 KV 卸载的基础目标，即在有限 GPU 显存下扩展容量并降低重算成本；但它显著改变了问题的权重分布。随着多轮长会话、工具调用、多 agent 扇出和前缀共享的普及，KV 卸载不再只是容量优化，而成为生命周期管理、共享调度和恢复路径优化的核心部分。对 CPU 而言，这意味着其在未来推理系统中的角色将不只是通用 host，而更可能是 GPU 外第一个可参与推理关键路径的容量层与共享层。

10. 参考来源

- NVIDIA, Full-Stack Optimizations for Agentic Inference with NVIDIA Dynamo: https://developer.nvidia.com/blog/full-stack-optimizations-for-agentic-inference-with-nvidia-dynamo/
- NVIDIA, How to Reduce KV Cache Bottlenecks with NVIDIA Dynamo: https://developer.nvidia.com/blog/how-to-reduce-kv-cache-bottlenecks-with-nvidia-dynamo/
- NVIDIA, Accelerate Large-Scale LLM Inference and KV Cache Offload with CPU-GPU Memory Sharing: https://developer.nvidia.com/blog/accelerate-large-scale-llm-inference-and-kv-cache-offload-with-cpu-gpu-memory-sharing/
- NVIDIA, Introducing New KV Cache Reuse Optimizations in NVIDIA TensorRT-LLM: https://developer.nvidia.com/blog/introducing-new-kv-cache-reuse-optimizations-in-nvidia-tensorrt-llm/
- INFERCEPT paper: https://arxiv.org/pdf/2402.01869
- Preble paper: https://arxiv.org/pdf/2407.00023